Week 12

탐색적 데이터 분석과 프로젝트 기획

AI활용코딩연습(ZBE135)
이영호 교수 · 국립목포대학교 컴퓨터학부

지난주 돌아보기

```
survey = clean_survey(raw)                          # 정제 파이프라인
survey.groupby("department").agg(ai_rate=("uses_ai", "mean"))
survey.merge(depts, on="department", validate="many_to_one")
```

- 정제 계획 표 → 파이프라인 → 전후 비교 → 테스트
- 오늘: 깨끗한 데이터로 **질문에 답하는 탐색**, 그리고 **최종 프로젝트 기획**

오늘의 목표

1. **EDA 절차**: 질문 → 데이터 이해 → 단변량 → 이변량·그룹 → 발견 정리
2. 날짜 · 시각 **파생 변수**와 **집계 단위**(건수 · 수량 · 매출) 구분
3. 그룹마다 일수가 다르면 **일평균**으로 공정하게 비교
4. 두 데이터를 합쳐 관계를 보고, **상관 ≠ 인과** 구분
5. 최종 프로젝트 **연구 질문**과 **제안서** 작성

수업 흐름

구간	시간	활동
도입 · 개념	20분	EDA 절차, 한 행의 의미, 집계 단위
안내 실습	45분	파생 변수, 메뉴 · 요일 · 시간대 · 시험 기간
독립 · 짝 실습	35분	기온과 판매, AI 해석 검증
공유 · 점검	20분	연구 질문 다듬기, 제안서 안내

이번 주 Colab 실습 열기

EDA 절차

단계	질문	도구
① 질문	무엇을 알고 싶은가?	연구 질문 목록
② 데이터 이해	**한 행은 무엇?** 기간 · 단위 · 결측	`info`, `describe`
③ 단변량	각 변수의 분포	`value_counts`, 히스토그램
④ 이변량 · 그룹	변수끼리 · 그룹끼리	`groupby`, `pivot_table`, `corr`
⑤ 발견 정리	숫자 + 비교 기준 + 한계	발견 표

오늘의 데이터와 질문

캠퍼스 카페 판매 `cafe_sales.csv` (2025년 1학기, 가상) + **기온** `weather_daily.csv`

- Q1. 어떤 메뉴가 매출을 이끄는가?
- Q2. 언제(요일 · 시간대) 가장 바쁜가?
- Q3. 시험 기간에 판매가 달라지는가?
- Q4. 기온은 판매와 관련이 있는가?

> 질문이 있어야 **무엇을 계산할지** 정해진다

한 행의 의미와 집계 단위

한 행 = 주문 한 건의 메뉴 한 종류 (`qty` = 수량)

단위	계산	답하는 질문
주문 건수	행 수	얼마나 자주 주문되나
판매 수량	`qty` 합	몇 잔 팔렸나
매출	`unit_price × qty` 합	얼마나 벌었나

"인기 메뉴"는 무엇 기준인가? → **먼저 정한다**

파생 변수

```
cafe["revenue"] = cafe["unit_price"] * cafe["qty"]
cafe["month"] = cafe["date"].dt.month
cafe["weekday"] = pd.Categorical(
    cafe["date"].dt.dayofweek.map(dict(enumerate("월화수목금토일"))),
    categories=list("월화수목금토"), ordered=True)
cafe["hour"] = cafe["time"].str[:2].astype(int)
cafe["daypart"] = pd.cut(cafe["hour"], bins=[7, 10, 13, 16, 19],
                         labels=["아침", "점심", "오후", "저녁"])
```

순서 있는 `Categorical` → 정렬 · 그래프가 **월화수…** 순서

Q1. 메뉴: 세 기준 비교

메뉴	주문 순위	매출 순위	매출 비중
아메리카노	1	1	23.6%
카페라떼	2	2	18.6%
레몬에이드	7	**5**	7.5%
베이글	**5**	7	5.7%

가격이 다르면 **건수 순위 ≠ 매출 순위**

Q2. 요일: 합계 말고 일평균

```
daily = cafe.groupby("date").agg(revenue=("revenue", "sum"))
by_wd = daily.groupby("weekday").agg(days=("date", "size"),
                                     per_day=("revenue", "mean"))
pivot.div(by_wd["days"], axis=0)        # 요일 × 시간대 일평균
```

	아침	점심	오후	저녁
화	43.6	**74.8**	34.7	15.8
토	19.3	27.7	12.2	8.5

(천 원) 평일 **점심**이 가장 바쁘다, 토요일은 평일의 절반 이하

Q3. 시험 기간

구분	일수	일평균 주문	일평균 매출
평상시 (평일)	70	34	159,036원
시험 주간	**10**	41	205,100원

- 차이가 있어 보이지만 시험 주간은 **10일뿐**
- 결론에 **"10일 기준"** 같은 단서를 붙인다

Q4. 두 데이터 합치기

```
day_df = (daily.merge(ice_ratio, on="date", how="left")
               .merge(weather[["date", "avg_temp"]], on="date",
                      how="left", validate="one_to_one"))
assert len(day_df) == len(daily)
day_df[["avg_temp", "ice_ratio", "revenue"]].corr()
```

	기온과의 상관
아이스 비율	**0.85**
일 매출	0.10

기온 구간별 비교

평균기온	일수	아이스 비율	일평균 매출
10℃ 미만	23	26.0%	140,565
10~15	28	41.4%	151,229
15~20	19	53.3%	156,553
20~25	19	71.9%	144,632
25℃ 이상	6	81.3%	168,017

아이스 비율은 **뚜렷이** 증가, 매출은 **뚜렷한 경향 없음**

상관 ≠ 인과

- 기온과 아이스 비율의 상관이 높다 → "기온이 **원인**"이라고 말할 수 있나?
- 같은 시기에 **계절, 시험 일정, 학사 일정**도 함께 바뀐다
- 이 데이터로 말할 수 있는 것: "**함께 변한다**"

말해도 되는 것	말하면 안 되는 것
기온이 높은 날 아이스 비율이 높았다	기온을 올리면 아이스가 팔린다
시험 주간 일평균 주문이 많았다 (10일)	시험이 판매를 늘린다

발견 정리: 숫자 + 기준 + 한계

발견	근거	주의점
아메리카노·라떼가 매출의 40% 이상	메뉴별 매출 비중	한 학기 데이터
평일 점심, 특히 12시가 가장 바쁨	요일×시간대 일평균	일요일 휴무
기온↑ → 아이스 비율↑ (26% → 81%)	상관 0.85, 구간 비교	상관이지 인과 아님
시험 주간 주문 증가 (34 → 41건)	평일 비교	10일뿐

AI 해석 검증

AI: "가장 인기 있는 메뉴는 아메리카노이며, **주문의 40% 이상**"
→ 실제: 건수 29.1% · 수량 28.9% · 매출 23.6% — **과장**, 기준도 없음

AI: "**3월 매출이 6월보다 훨씬 높으므로** 학기 초에 수요가 몰린다"
→ 6월은 20일까지(영업일 17일), **일평균은 6월이 더 높음**

AI: "기온이 오르면 매출 증가 → **가격 인상**"
→ 상관 0.1로 약함, 인과도 아님, 가격 효과는 알 수 없음

AI에게 분석을 맡길 때

```
cafe_sales.csv의 한 행은 '주문 한 건의 메뉴 한 종류'이고 qty는 수량입니다.
- '인기'는 판매 수량 기준으로, 비율은 계산 코드와 함께 보여 주세요.
- 월·요일 비교는 영업일 수가 다르므로 일평균으로 비교하세요.
- 상관관계를 인과로 해석하지 말고, 주장마다 근거 표를 제시하세요.
```

AI의 **문장**이 아니라 **문장을 만든 계산**을 요구하고 직접 실행

최종 프로젝트 개요

항목	내용
주제	연구 질문 2~3개에 답하는 **재현 가능한** 분석
데이터	수업 데이터 또는 공개 데이터 (출처 · 이용 조건 명시)
산출물	Colab 노트북 · README · 5분 발표 · AI 활용 · 성찰 보고서
일정	12주 제안서 → 13주 시각화 → 14주 테스트 · 리팩토링 → 15주 발표

좋은 연구 질문

막연한 질문	좋은 질문
카페 매출을 분석한다	평일 점심 매출은 다른 시간대보다 얼마나 높은가?
날씨가 영향을 줄까?	기온 구간별로 아이스 음료 비율은 어떻게 달라지는가?
AI를 많이 쓸까?	AI 사용 여부에 따라 학년별 만족도에 차이가 있는가?

체크: **데이터로 답할 수 있나 · 비교 대상이 있나 · 표/그래프로 보일 수 있나 · 2주 안에 가능한가**

데이터 후보

데이터	질문 예
`cafe_sales` + `weather_daily`	시간대 · 요일 · 기온 · 시험 기간별 판매
`survey_raw` (정제) + `departments`	AI 사용과 코딩 시간 · 만족도
`students`	출석 · 과제와 성적 (가상 데이터 한계)
공공데이터포털 · 기상자료개방포털 · KOSIS	직접 고른 주제

> 공개 데이터는 **출처와 이용 조건**을 확인하고 README에 적는다

제안서 구성

1. **연구 질문** 2~3개
2. **데이터**: 출처 · 이용 조건 · 한 행의 의미 · 기간 · 주요 열
3. **분석 방법**: 정제 계획 · 비교 · 집계 방법 · 예상 그래프 2~3개
4. **예상 결과와 한계**
5. **AI 활용 계획**: 어디에 쓰고 어떻게 검증할지

이번 주 과제 문제 4에 **초안**을 작성 → 13주차 피드백

이번 주 과제 (10점)

문제	내용	배점
1	`add_features` 시간 파생 변수	2
2	`weekday_daypart` 요일 × 시간대 **일평균** 매출표	2
3	`menu_share` · `top80` 매출 비중과 누적 80%	3
4	`temp_bands` 기온 구간 분석 (AI 협업) + **프로젝트 제안서**	3

자기 점검

1. `cafe_sales.csv`에서 "한 행"의 의미는?
2. 주문 건수 · 판매 수량 · 매출 순위가 다를 수 있는 이유는?
3. 월별 매출을 합계로 비교하면 안 되는 경우는?
4. 상관계수 0.85가 뜻하는 것과 뜻하지 않는 것은?
5. 좋은 연구 질문의 네 가지 조건은?

정리와 다음 주

오늘	핵심
EDA	질문 → 이해 → 단변량 → 그룹 → 발견
단위	한 행의 의미, 건수 · 수량 · 매출
비교	일수가 다르면 일평균, 작은 표본 주의
해석	숫자 + 기준 + 한계, 상관 ≠ 인과
기획	구체적 연구 질문, 제안서

다음 주 · Week 13 matplotlib 데이터 시각화